SAMSUNG

2025 Samsung Collegiate Programming Challenge

On-device 환경을 고려한 일상 이미지 이해 Multi-Modal AI 개발

: CLIP 유사도와 MOBILE VLM을 활용한 확신도 기반 VQA 전략

이 찬

Contents

01 문제 분석

- 문제 분석
- 문제 해결 전략 및 모델 설계

02 모델 경량화

- Mobile VLM v1
- LLM Pruner를 통한 Mobile LLama 경량화

03 성능 향상 전략

- LoRA Finetuning with Train Data
- Prompt Engineering
- Top-2 Similarity Margin 기반 조건부 앙상블

04 결론

- 최적화 및 문제 해결 전략 평가
- SCPC 대회 규정 만족 여부

Part1
문제 분석

1-1. 문제 분석

1-2. 문제 해결 전략 및 모델 설계

문제 분석

사용자의 갤러리에 있는 다양한 일상 사진을 입력으로 받아
해당 이미지에 대한 선다형 질문에 정답을 추론

Q: What might be the purpose of the person's workout in the image?

(A) Building muscle and strength
(B) Practicing for a marathon
(C) Training for a cycling race
(D) Preparing for a swimming competition

Answer : A

문제 해결 전략 및 모델 설계

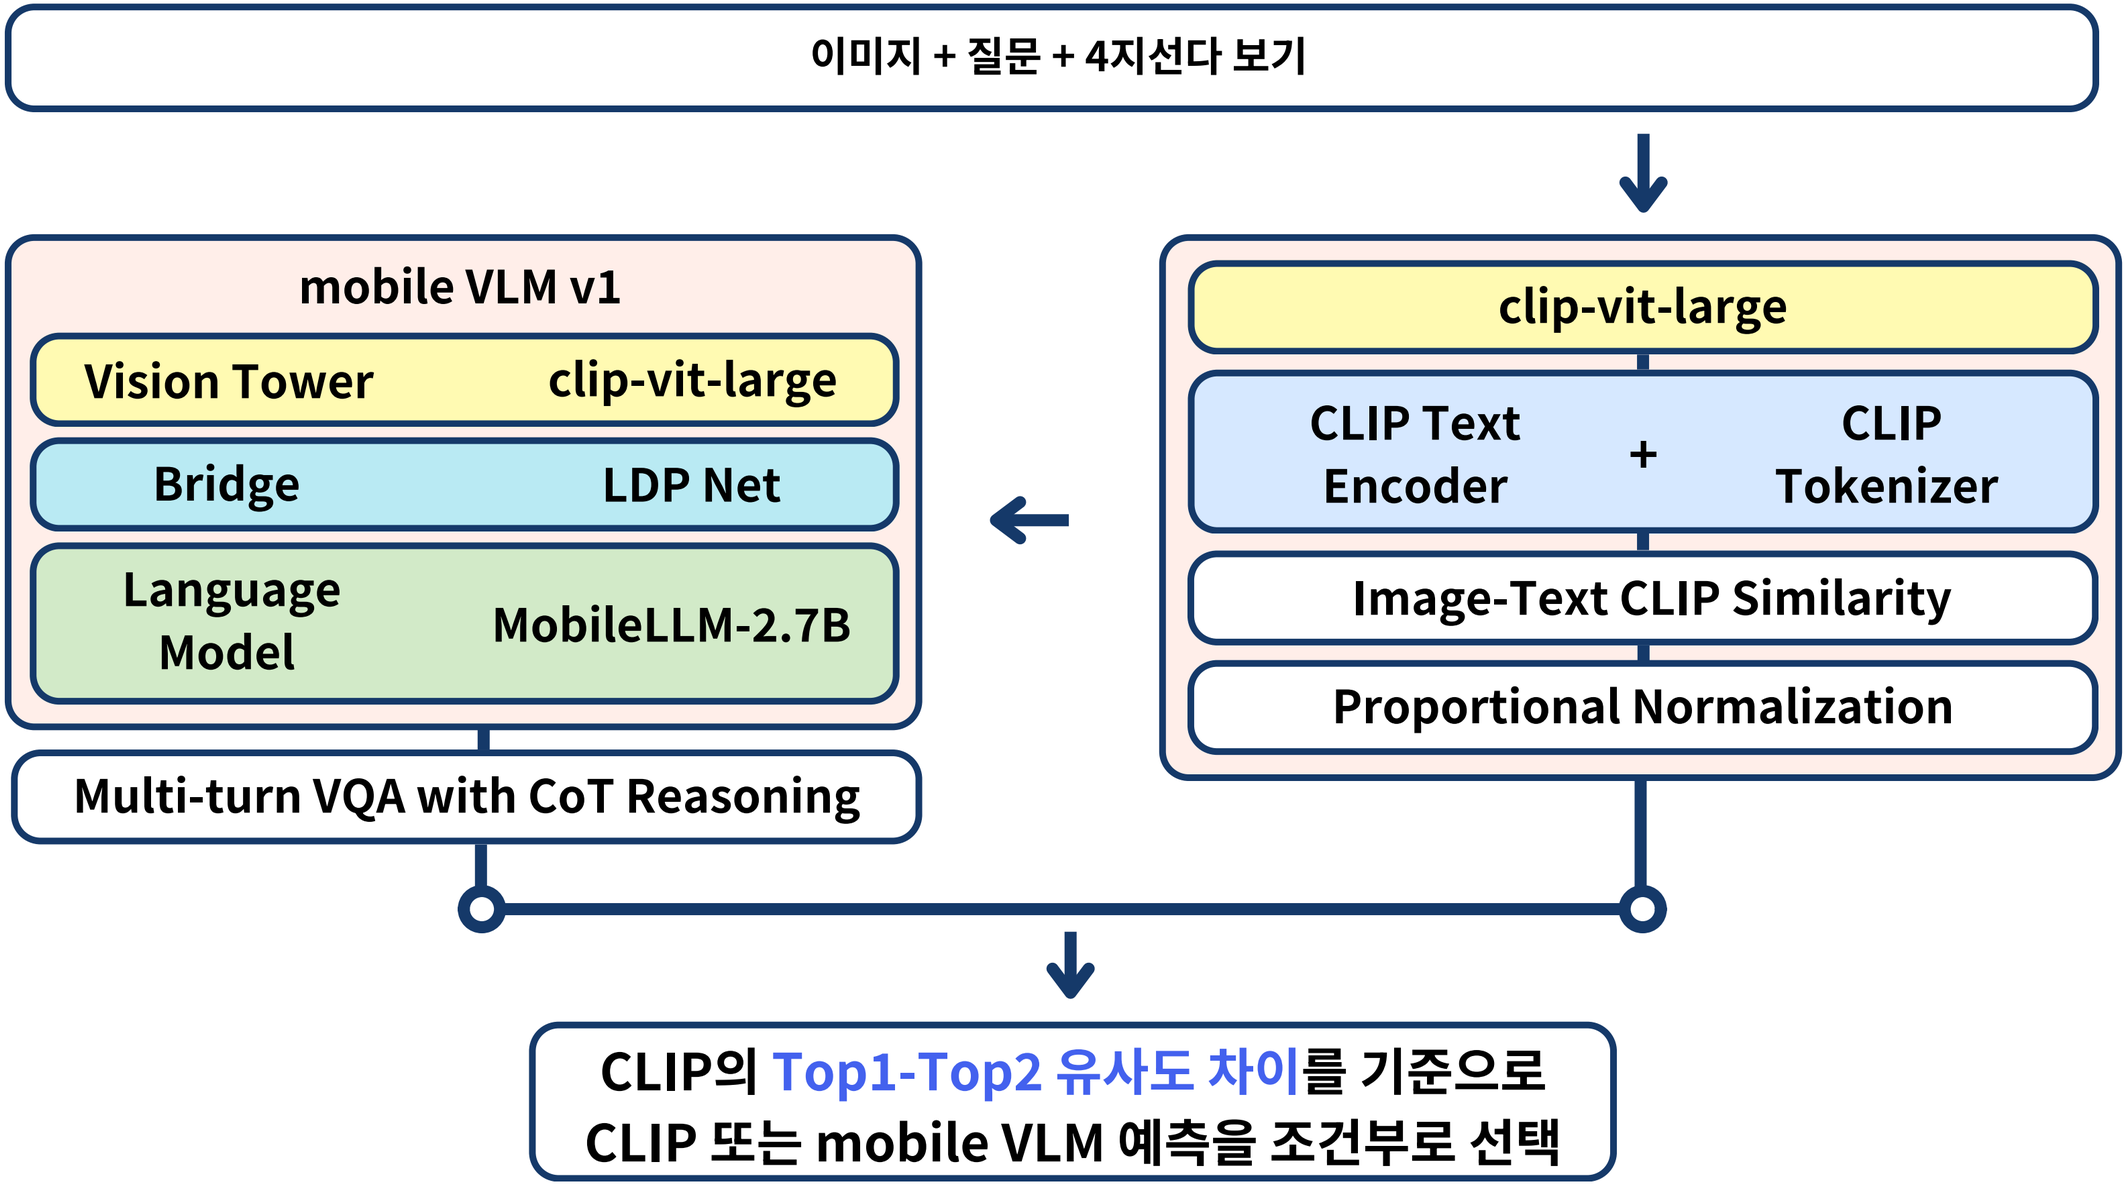

문제 해결 전략 및 모델 설계

이미지 + 질문 + 4지선다 보기

Multi-turn VQA with CoT Reasoning

CLIP의 Top1-Top2 유사도 차이를 기준으로
CLIP 또는 mobile VLM 예측을 조건부로 선택

서로 다른 성격의 두 모델을 활용하여 문제를 해결

- **CLIP:** 시각 정보를 활용하여 빠르게 판단을 수행하는 초기 판단자
- **mobile VLM:** 논리적 추론을 통해 최종 답변을 도출하는 문제 해결자

Part 2
모델 경량화

2-1. Mobile VLM v1

2-2. LLM Pruner를 통한 Mobile LLama 경량화

Mobile VLM v1

MobileVLM : A Fast, Strong and Open Vision Language Assistant for Mobile Devices

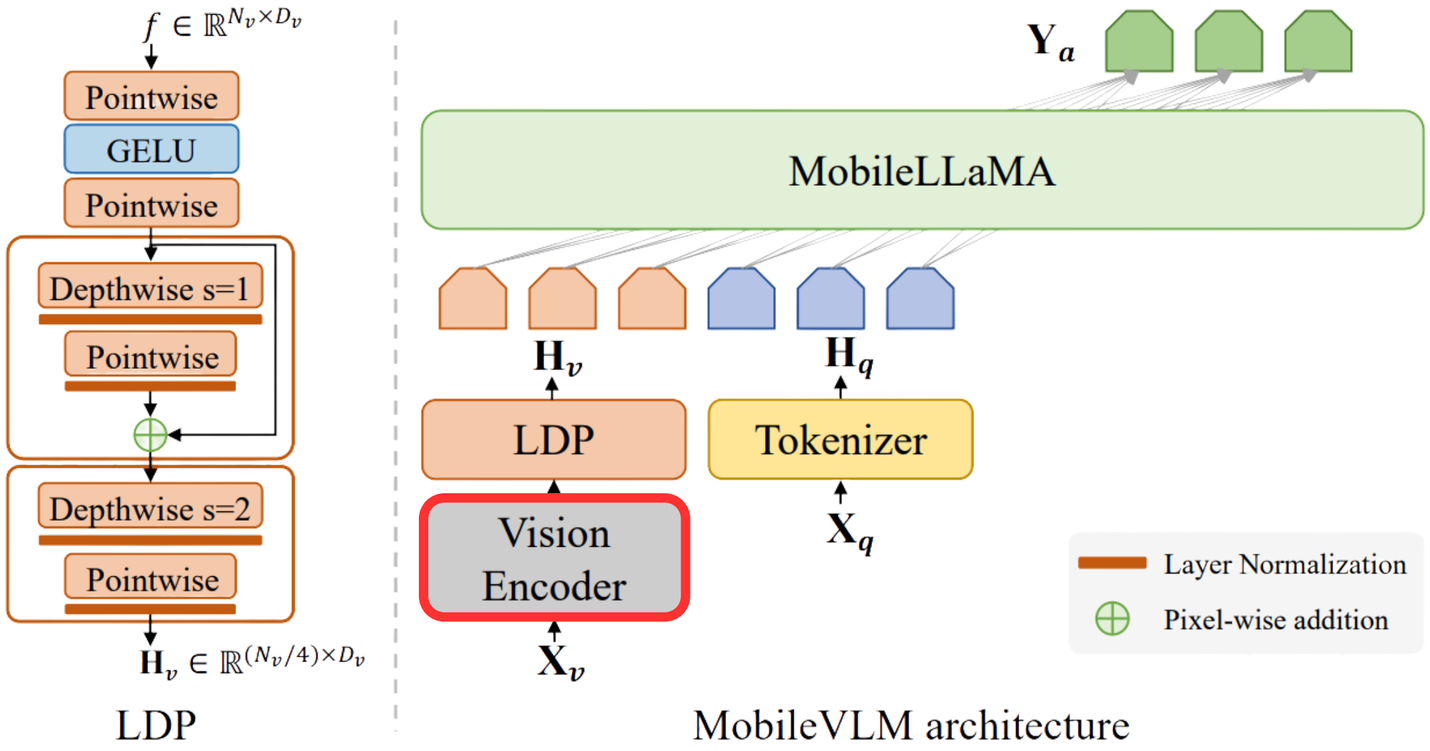

- MobileVLM에서 사용된 CLIP은 시각 인식용 vision encoder로 활용됨
- CLIP 모델의 텍스트 인코더는 제거되고, LDP 구조를 통해 Mobile LLaMA와 연결되어 있음

➡ 이미지-텍스트 유사도 기반의 CLIP 판단을 위해 CLIP의 텍스트 인코더를 별도로 로드 필요

LLM Pruner를 통한 Mobile LLama 경량화

LLM-Pruner: On the Structural Pruning of Large Language Models
Xinyin Ma et al., NeurIPS 2023

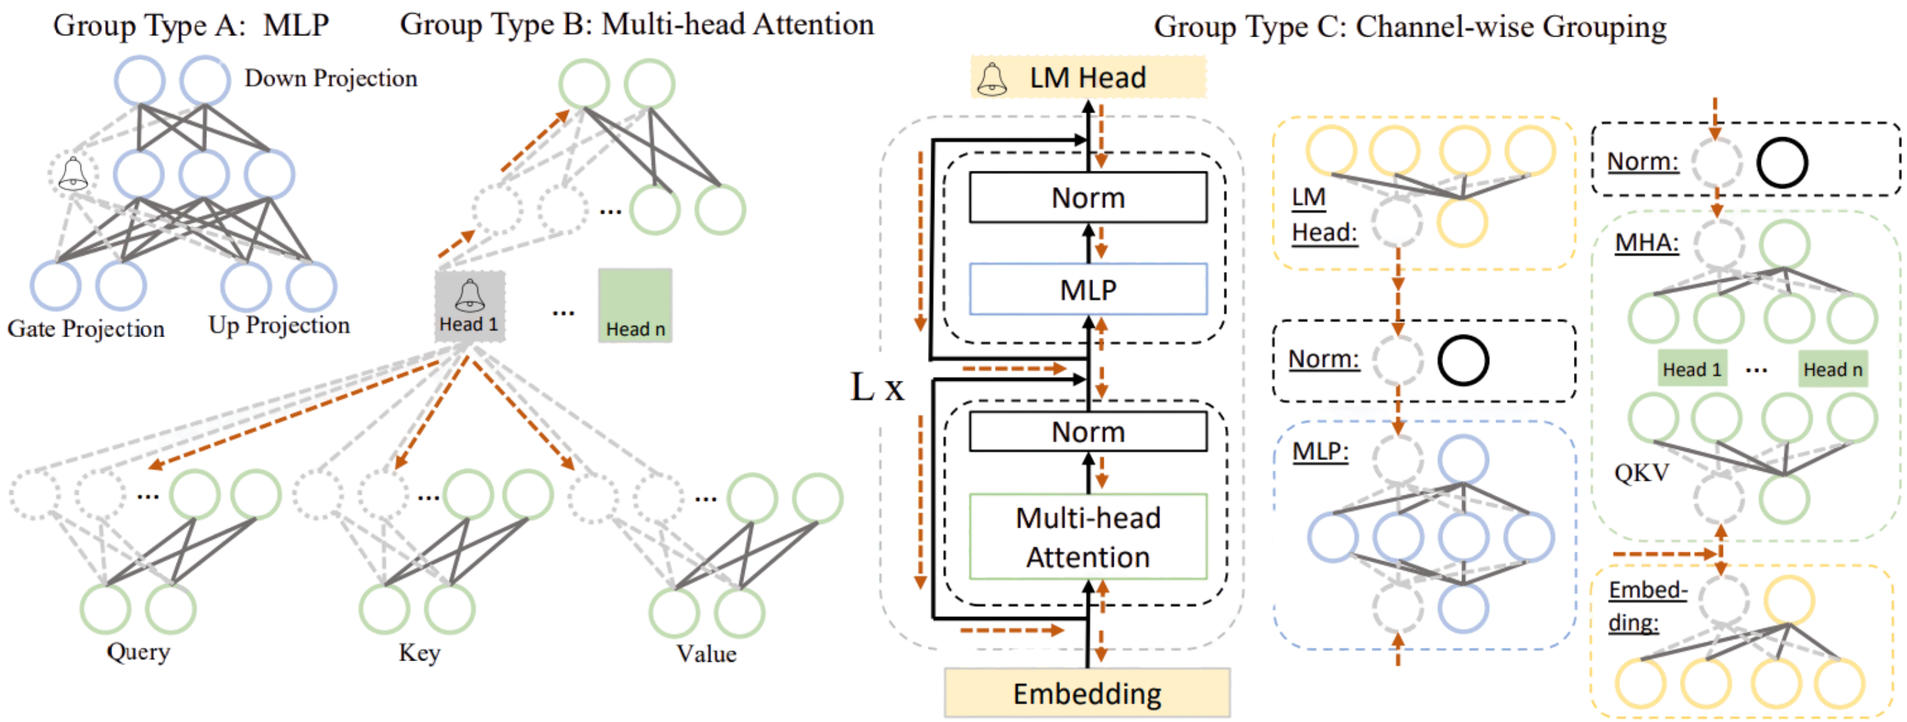

- 모델 내 상호 의존적인 구조들을 그룹 단위로 식별
- 그룹 전체의 중요도를 저비용 연산으로 평가하고, 이를 기반으로 구조적 프루닝을 수행하는 방법
- 추가적인 대규모 재학습 없이도 성능 저하를 최소화한 경량화 수행

LLM Pruner를 통한 Mobile LLama 경량화

Pruning 전략 1.
Attention Layer에 비해 **FFN Layer는 pruning 시 성능 하락이 상대적으로 적다.**

CFSP: An Efficient Structured Pruning Framework for LLMs with Coarse-to-Fine Activation Information
Wang et al., COLING 2025

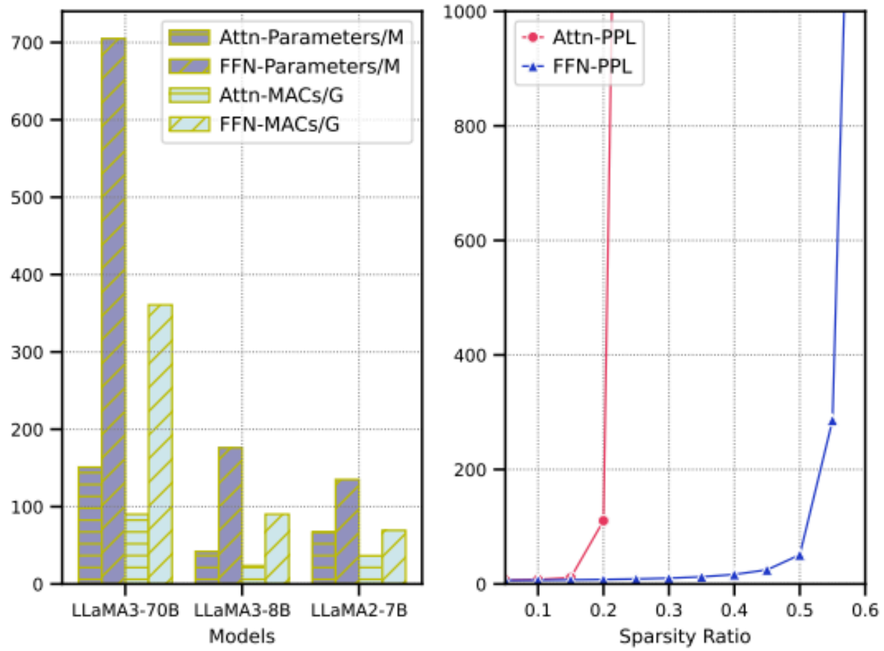

Figure 2: Preliminary analysis. (Left): Parameter size and MACs of modules. (Right): Sensitivity of pruning each module on LLaMA2-7B.

Pruning 전략 2.
SwiGLU 기반 FFN 구조에서는, FFN pruning 시 채널 단위의 **구조적(structured) pruning이 성능 유지를 위해 필수적**이다.

GLU Variants Improve Transformer
Noam Shazeer, arXiv 2020

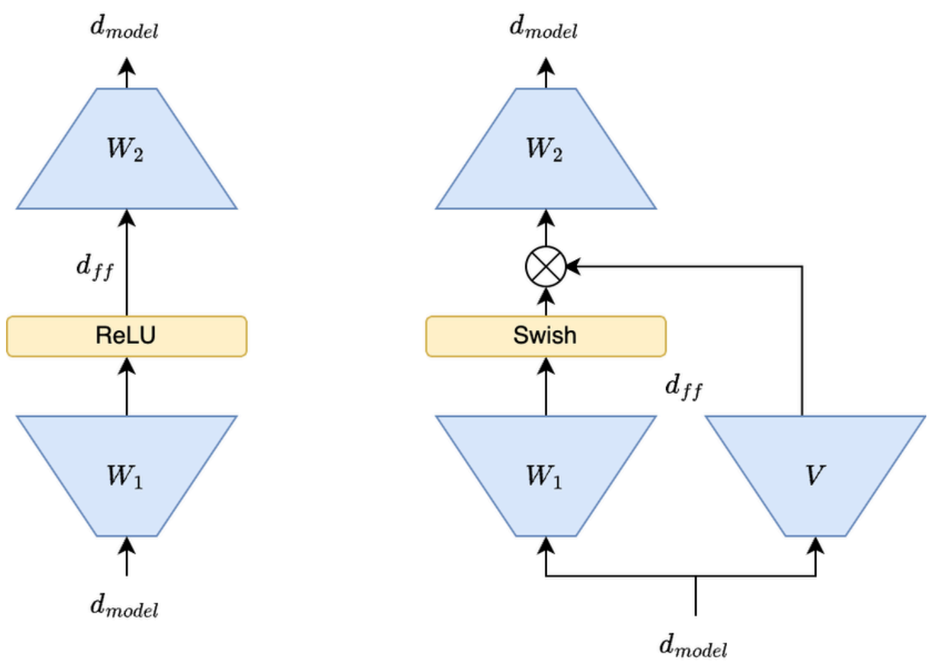

Original Feed Forward Layer

Feed Forward with SwiGLU

LLM Pruner를 통한 Mobile LLama 경량화

Pruning MobileLLaMA 2.7B

- **Pruning 전 전체 파라미터 수 : MobileVLM 3.034B + CLIP Text Encoder 0.123B = 3.158B**
- Pruning 대상: MobileVLM 내 언어 모델(Mobile LLaMA) 부분에만 pruning 적용
- Pruning 적용 범위 : 전체 32개 레이어 중 시작 및 끝단 레이어를 제외한 모든 FFN(MLP) & Attention layer
- Pruning 비율 : Mobile LLaMA 기준 2.702B → 2.5785B (5.86% 제거)
- Calibration Dataset : Train Data

Pruning 결과

Pruned Mobile VLM : **2.871B**

Clip Text Encoder : **0.124 B**

Total Parameter : **2.996 B**

Part3
성능 향상 전략

3-1. LoRA Finetuning with Train Data

3-2. Prompt Engineering

3-3. Top-2 Similarity Margin 기반 조건부 앙상블

LoRA Finetuning with Train Data

Low Rank Adaptation

- 대회에서 제공된 Train 데이터를 사용하여, Task-specific & Parameter-efficient Fine-tuning
- MobileVLM의 언어 모델(Mobile LLaMA) 내 Attention Layer와 FFN Layer 전반에 적용
- Fine-tuning 이후, LoRA 어댑터를 pruned model의 base weight에 merge

  → 최종 모델의 파라미터 수는 pruning 이후와 동일하게 유지

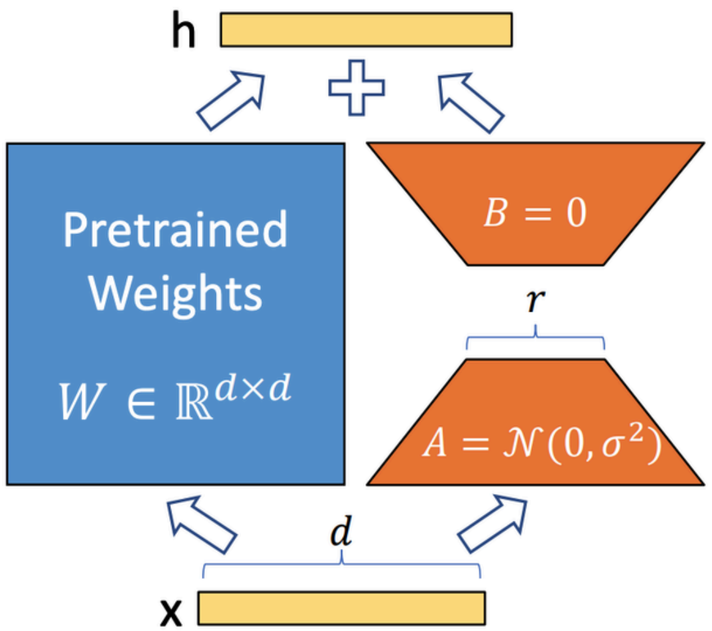

Prompt Engineering

1단계 **Visual Analysis / Captioning**	**<Image>** **Analyze the image in a comprehensive and detailed manner.**
2단계 **분석 결과를 활용한 문제 풀이**	**[Image Analysis Result]** **Question: ...** **Choices:** **A. ...** **B. ...** **C. ...** **D. ...** **Answer with only the alphabet of the correct option.**

Multi-turn Prompting

하나의 프롬프트에서 바로 답변을 요구하지 않고, 이미지 이해 → 추론 → 답변의 단계를 명시적으로 분리함으로써 시각 정보 해석의 안정성과 일관성을 향상시킴.

Chain-of-Thought

이미지 분석 단계에서 모델이 시각적 근거를 명시적으로 서술하도록 유도하여, 내부 추론 과정을 외부 텍스트 형태로 드러내게 함. 이를 통해 최종 답변이 시각적·논리적 추론의 결과가 되도록 설계

Top-2 Similarity Margin 기반 조건부 앙상블

Q: What type of clothing are the people wearing, and what does it suggest about the climate?

CLIP 확신도 해석을 위한 비례 정규화

A: The people are wearing light clothing, suggesting a warm and sunny climate.
→ similarity 0.1529
B: The people are wearing swimwear, suggesting a tropical and beach-like climate.
→ similarity 0.1076
C: The people are wearing heavy coats, suggesting a cold and possibly snowy climate.
→ similarity 0.2187
D: The people are wearing raincoats, suggesting rainy and wet weather conditions.
→ similarity 0.1383

A: The people are wearing light clothing, suggesting a warm and sunny climate.
→ normalized proportion 0.2476
B: The people are wearing swimwear, suggesting a tropical and beach-like climate.
→ normalized proportion 0.1743
C: The people are wearing heavy coats, suggesting a cold and possibly snowy climate.
→ normalized proportion 0.3542
D: The people are wearing raincoats, suggesting rainy and wet weather conditions.
→ normalized proportion 0.2239

- **CLIP 유사도 점수에 문항별 비례 정규화를 적용하여 보기 간의 스케일 차이를 보정**
- **정규화된 값은 각 보기가 정답일 확률로 해석되며, 이를 통해 각 보기마다 모델이 얼마나 확신하고 있는지 파악 가능**
- **Top1과 Top2 간의 점수 차이는 Clip 모델의 문항에 대한 확신도(confidence)의 의미로 해석**

Top-2 Similarity Margin 기반 조건부 앙상블

최종 Top1 - Top2 Margin Threshold : 0.827

- Train 데이터 분석 결과, CLIP 단독 판단의 정확도가 100%로 안정화되면서, 가장 높은 문제 커버리지를 확보하는 지점
- 확률 차이(Top1 - Top2)가 threshold 0.827을 초과한 문제는 CLIP이 높은 확신을 가진 것으로 판단하고, CLIP의 예측 결과를 최종 정답으로 채택
- threshold를 넘지 못한 문제는 CLIP으로 해결하기 어려운 상식 기반 추론 문제로 간주하여, mobileVLM 모델의 언어 기반 추론 결과를 최종 정답으로 사용

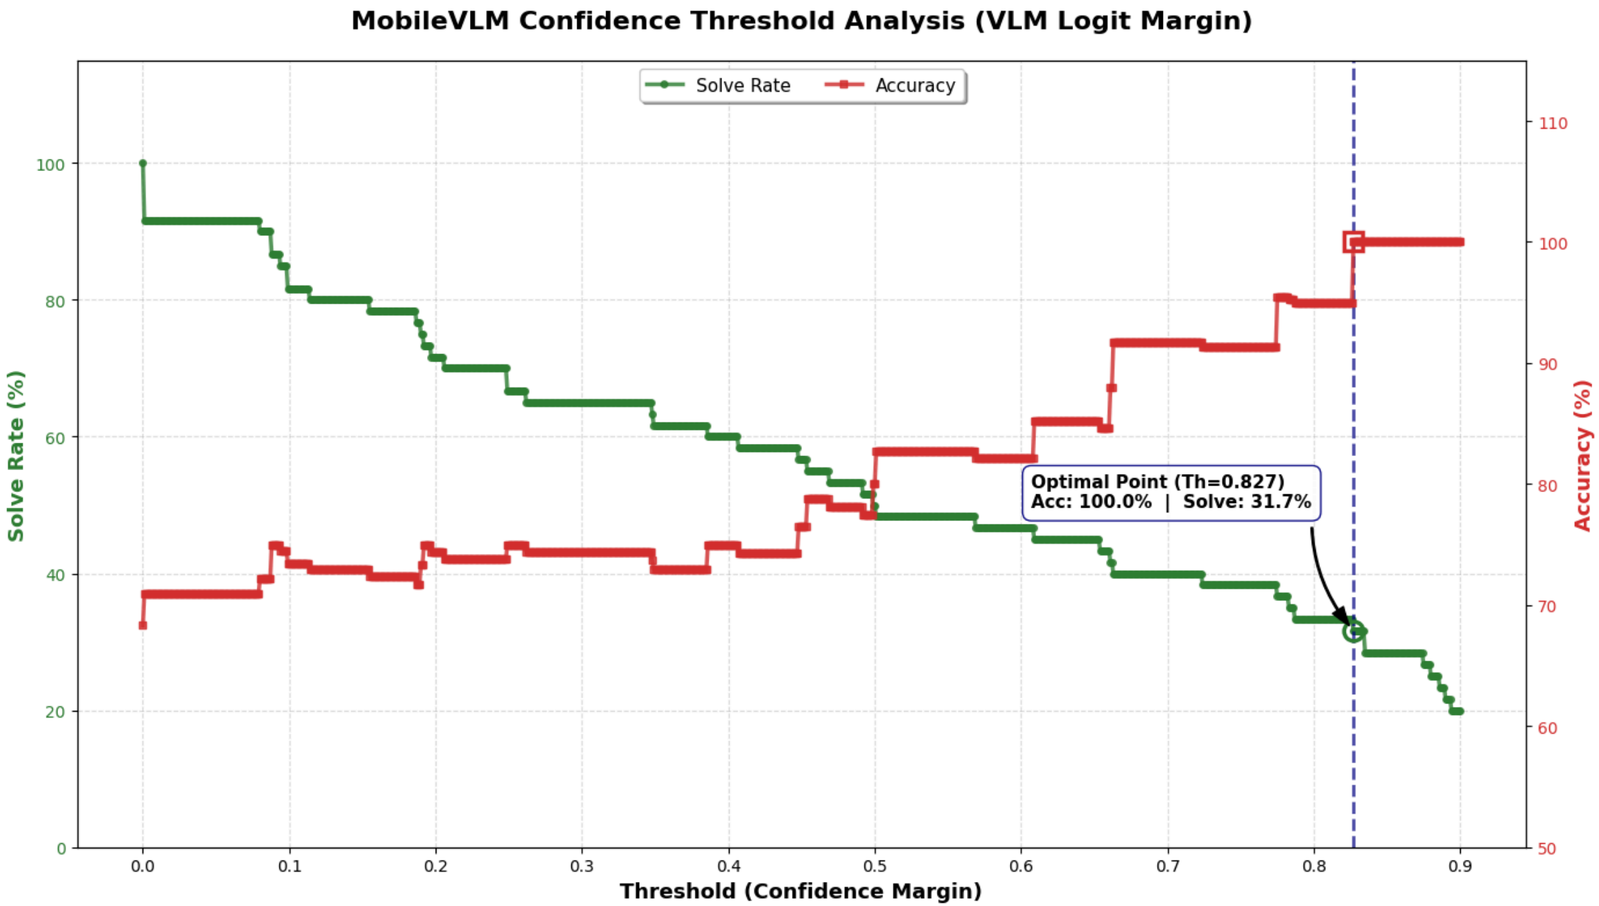

최종 Model 성능

Pruned Mobile VLM

PUBLIC SCORE
0.6652

Pruned Mobile VLM
+ Multi turn prompt

PUBLIC SCORE
0.7269

LoRA Fine Tuning

PUBLIC SCORE
0.7356

확신도 기반 조건부 앙상블

PUBLIC SCORE
0.7839

최종 SCORE

PUBLIC SCORE	PRIVATE SCORE
0.78394	0.76525

Part4
결론

3-1. 최적화 및 문제 해결 전략 평가

3-2. SCPC 대회 규정 만족 여부

최적화 및 문제 해결 전략 평가

문제 난이도·유형에 따른 확신도 기반 문제 해결 전략으로 추론 연산량 감소

CLIP의 이미지–텍스트 유사도 분포를 기반으로 모델의 확신도를 산출하고, 확신도가 높은 문제는 CLIP 단독으로 처리하며, 논리적 추론이 요구되는 문제에 대해서만 Multi-turn 방식의 MobileVLM 추론을 적용함. 이를 통해 문제의 난이도와 유형에 적응적으로 대응하면서, **불필요한 추론 연산을 줄이고 전체 추론 비용을 효과적으로 감소**시킴.

CLIP의 이중 역할 활용을 통한 파라미터 효율적 설계

초기 단계에서는 지각 기반 판단자로 활용되어 시각적 단서가 명확한 문제를 빠르게 해결하고, 동시에 MobileVLM 내부에서는 시각 인식의 핵심 모듈로 사용함. 이와 같은 **이중 역할 구조를 통해** 별도의 추가 모델 도입 없이 시각 인식과 판단 기능을 공유함으로써, **전체 시스템의 파라미터 효율성과 구조적 간결성을 확보함.**

SCPC 대회 규정 만족 여부

모델 이름	총 파라미터 수	사전학습 가중치 공개일	라이선스	사용 조건 만족 여부
MobileVLM v1	3.034 B (original) 2.871B (Pruned)	2023.12	Apache License 2.0	
CLIP Text Encoder	0.124 B	2023.12	MIT License	
총합	2.995B			

Q & A